📈 나만의 데이터로 미래를 예측하다

Orange3 선형 회귀 실습 보고서

— 두 변수의 관계를 스스로 찾아 예측 모델 만들기 —

학년 반 번호	지족고 10726	이름	한규빈	제출일	2026 . 9 . 23.

🎯 미션 우리 주변에는 '하나가 늘면 다른 하나도 규칙적으로 변하는' 관계가 많습니다. 공부 시간과 성적, 기온과 아이스크림 판매량, 팔로워 수와 좋아요 수처럼요. 이번 활동에서는 내가 직접 고른 두 변수(x, y)의 데이터를 모아 산점도를 그리고, 노코딩 머신러닝(ML) 도구 Orange3로 선형 회귀 예측 모델을 만든 뒤, 그 예측이 믿을 만한지 스스로 검증합니다.

🏆 이 보고서는 수행평가① **"Orange3 선형회귀 탐구"** 입니다. 만점 **30**점 · 기본점수**9**점 세 영역 각 10점(영역1·영역2·영역3)으로 채점합니다. ※ **AI(생성형 AI 포함)** 활용은 원칙적으로 금지합니다.

영역 1 데이터 이해 및 회귀식 추정 [10점]

📋 평가요소 (배점 근거)

① 선형 관계가 나타나는 탐구 주제·데이터를 목적에 맞게 선정하고, 독립·종속 변수의 관계를 올바르게 파악하였는가? → 1-1

② 산점도를 근거로 회귀식(y=ax+b)을 합리적으로 추정하였는가? → 1-2-1·1-2-2

③ 기울기·절편의 의미를 데이터 맥락에서 설명하였는가? → 1-3

1-1 탐구 주제와 데이터 정하기 (내 탐구 설계)

💡 어떤 관계를 예측해 볼까? 아래는 아이디어일 뿐입니다. 관심 분야에서 자유롭게 골라도 좋고, 직접 새로운 주제를 만들어도 됩니다.

분야	예시 주제 (독립변수 x → 종속변수 y)
일상·소비	기온 → 아이스크림(또는 음료) 판매량 · 광고비 → 매출액
학습·생활	공부 시간 → 시험 점수 · 수면 시간 → 집중도 자기평가 점수
사회·미디어	팔로워 수 → 게시물 좋아요 수 · 영상 길이 → 조회수
과학·환경	음료 온도 → 얼음 녹는 시간 · 용수철에 매단 무게 → 늘어난 길이
스포츠·건강	키 → 몸무게 · 연습 시간 → 기록(초·점수)

✅ 좋은 데이터의 조건

· 두 변수 모두 숫자(연속형)이고, 하나가 변하면 다른 하나도 대체로 함께 변하는 관계일 것

· 데이터 개수는 최소 8개 이상 (많을수록 회귀선이 안정적)

· 직접 측정·설문하거나 공공데이터(KOSIS·기상자료개방포털 등)에서 수집 — 출처를 반드시 기록

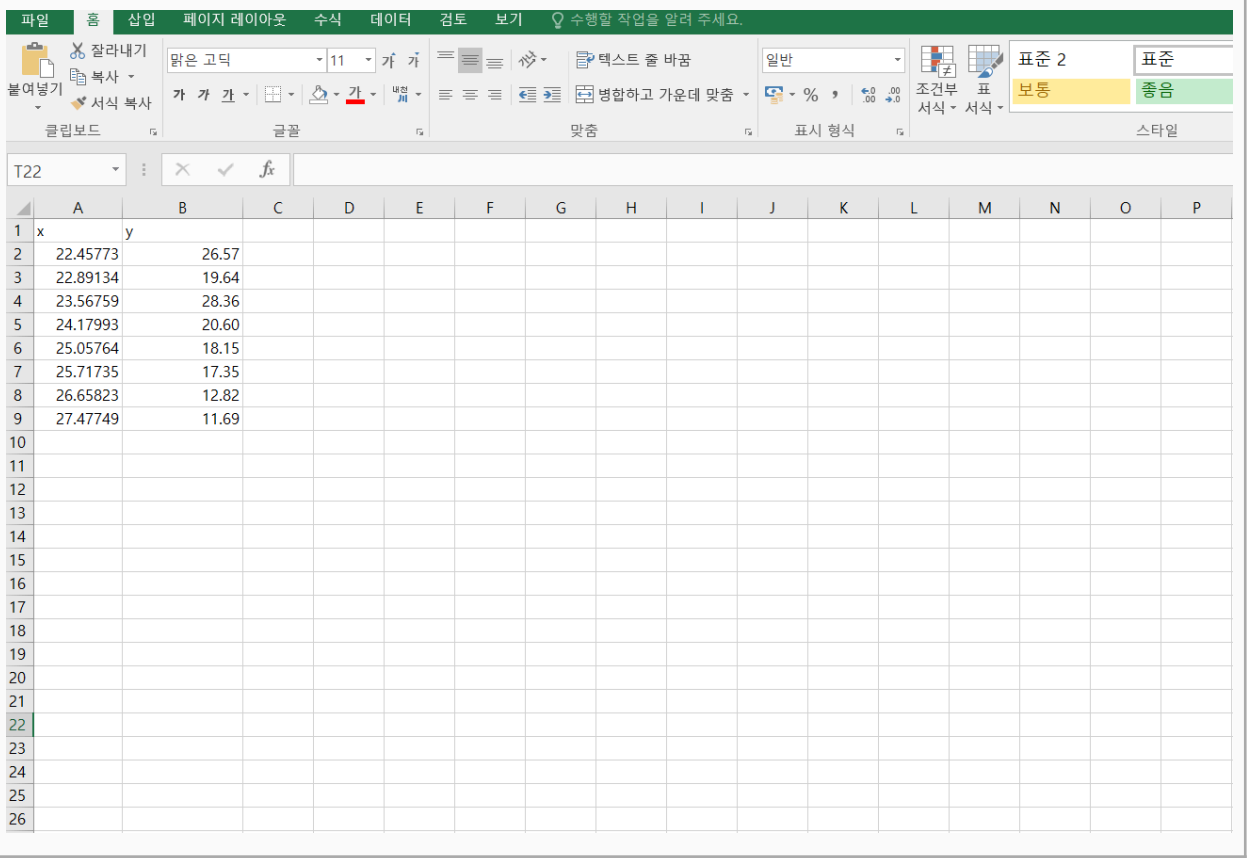
탐구 주제	전기차 보급률이 대기 오염에 미치는 영향
독립변수 **x**	전기차 보급률 (경기도 32개 지역) (전기 자동차 차량 수 / 전체 차량 수) * 1000
종속변수 **y**	PM2.5(초미세먼지) 농도 (μg/m³)
데이터 출처	공공데이터포털 - 국도교통부_자동차 등록 현황 공공데이터포털 - 한국전력공사_지역별 전기차 현황정보 KOSIS - 미세먼지(PM2.5) 월별 대기오염도/m³
예상 관계	전기차 보급률이 높을수록 대기 오염도가 낮을 것이다.

1-2-1 내 훈련 데이터 입력하기 (train.csv)

💡 수집한 훈련 데이터를 구글 시트나 엑셀에 입력하고 train.csv로 저장하세요. 첫 행은 변수 이름(x, y)으로 합니다.

독립변수 **x** (전기차 보급률)	종속변수 **y** (PM2.5 농도)
22.45773	26.57
22.89134	19.64
23.56759	28.36
24.17993	20.60
25.05764	18.15
25.71735	17.35
26.65823	12.82
27.47749	11.69

📷 구글 시트 또는 엑셀에 입력한 훈련 데이터 화면을 캡처하여 붙여넣기



	A	B
1	x	y
2	22.45773	26.57
3	22.89134	19.64
4	23.56759	28.36
5	24.17993	20.60
6	25.05764	18.15
7	25.71735	17.35
8	26.65823	12.82
9	27.47749	11.69

1-2-2 규칙을 찾아 회귀식 손으로 추정하기

🧠 x가 일정하게 커질 때 y는 얼마씩 변하나요? 표에서 규칙을 찾아 직선의 식 y = a x + b 로 손으로 추정해 보세요.

x가 1씩 커질 때 y는 약 2.8 만큼 감소한다. → 기울기 a ≈ -2.8 , 절편 b ≈ 90 . 따라서 y = -2.5 x +90 으로 예상한다.

1-3 기울기와 절편의 의미 해석

기울기 a는 이 데이터에서 무엇을 뜻하나요? 절편 b는 x=0일 때 무엇을 의미하나요? (내 주제의 맥락으로 설명)

{(전기차 수/전체 차량 수)*1000}이 1씩 늘어날 때, 초미세먼지는 2.8만큼 감소한다. 이를 실제 보급률로 환산하면, 전기차 보급률이 1%p 증가할 때 PM2.5 농도는 약 28μg/m³ 정도 감소하는 경향이 나타났다.

절편 90은 전기차가 없을 때 도시의 초미세먼지 양을 의미하는데, '매우 나쁨' 수준에 해당하는 양이다.

영역 2 — Orange3 예측 모델 구성 — [10점]

📋 평가요소 (배점 근거)

① train-test 데이터를 적절히 구성하였는가? → 1-2(train)·2-1(test)

② 워크플로우(File→Scatter Plot→Linear Regression→Predictions)를 올바르게 연결하였는가? → 2-2

③ 모델의 예측값을 산출하고 실제값(손 계산)과 비교하였는가? → 2-3

2-1 내 테스트 데이터 만들기 (test.csv)

💡 훈련 데이터 범위 안에서 x값 5개 정도를 골라 테스트 데이터(test.csv)를 만드세요. y열은 비워 둡니다.

독립변수 **x**	종속변수 **y** (비움)
22.5	?
23.5	?
24.5	?
25.5	?
26.5	?

2-2 Orange3 워크플로우 구성하기

📌 워크플로우 순서

① File 위젯 → train.csv 불러오기 (이름: train data)

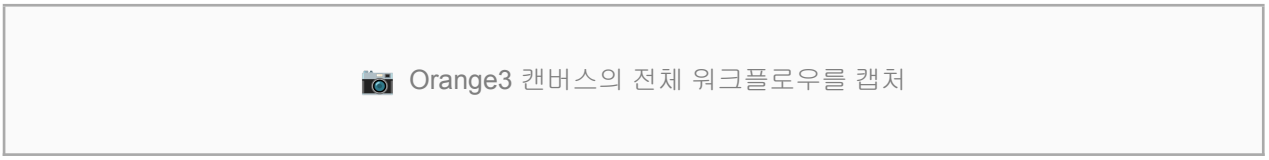
② Data Table 위젯 연결 → 데이터 확인

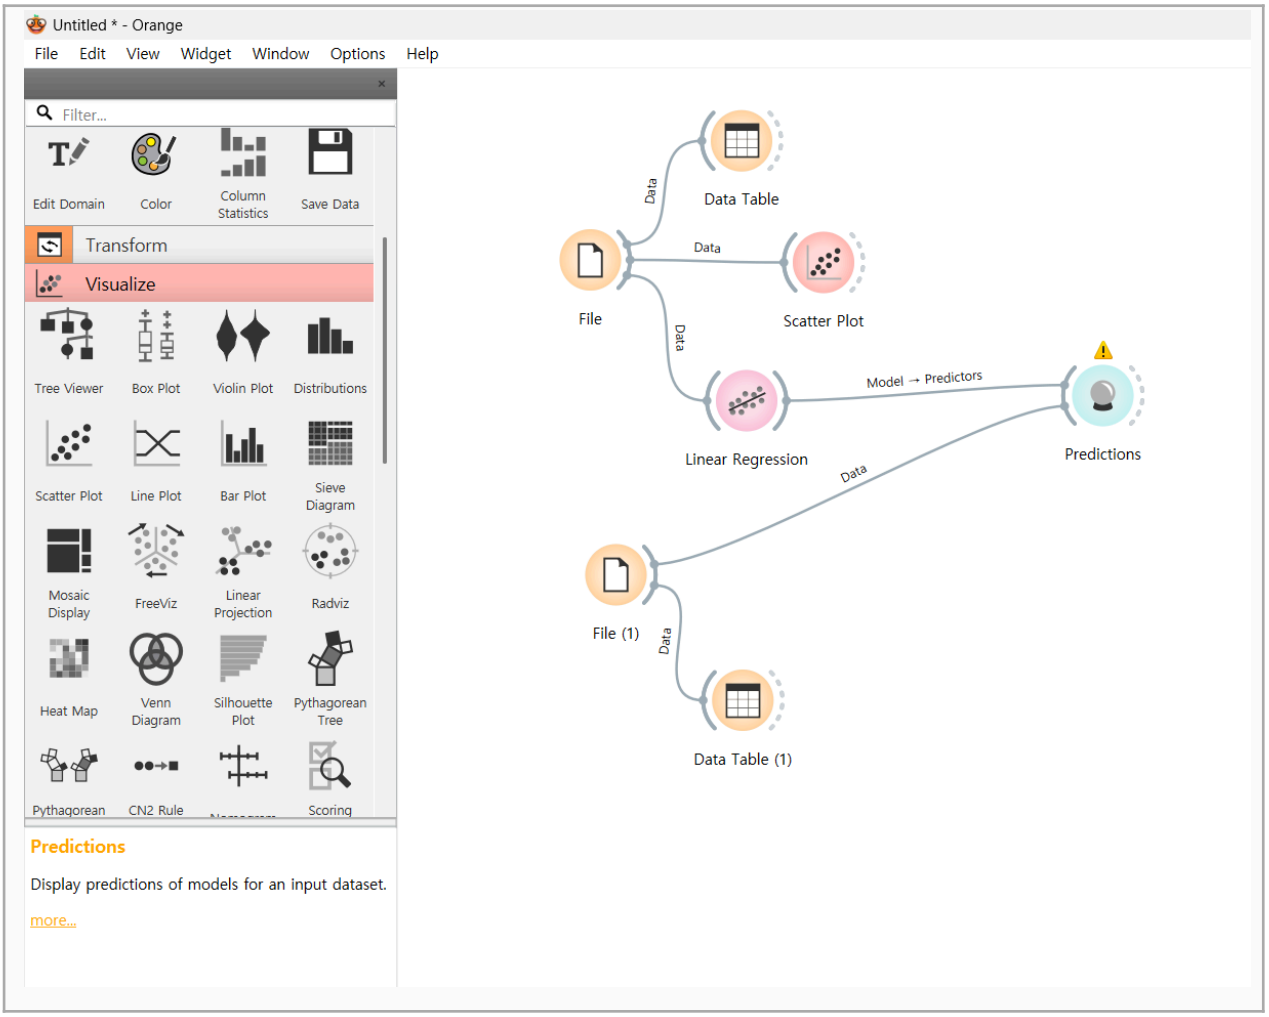
③ Scatter Plot 위젯 연결 → 산점도 확인 (x축: 독립변수, y축: 종속변수)

④ Linear Regression 위젯 연결 → 모델 학습

⑤ 새 File 위젯 → test.csv 불러오기 (이름: test data)

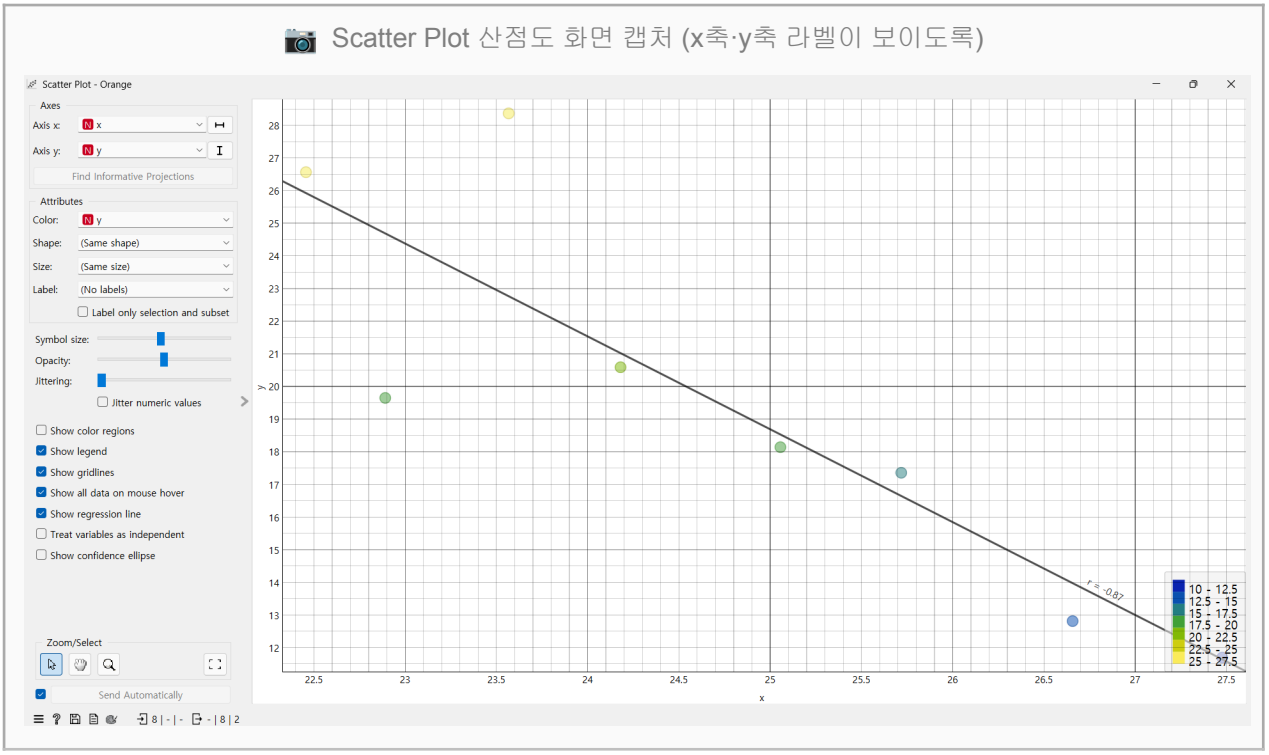
⑥ Predictions 위젯 → 모델 + 테스트 데이터 연결





산점도 확인 및 관찰

Scatter Plot 산점도 화면 캡처 (x축·y축 라벨이 보이도록)

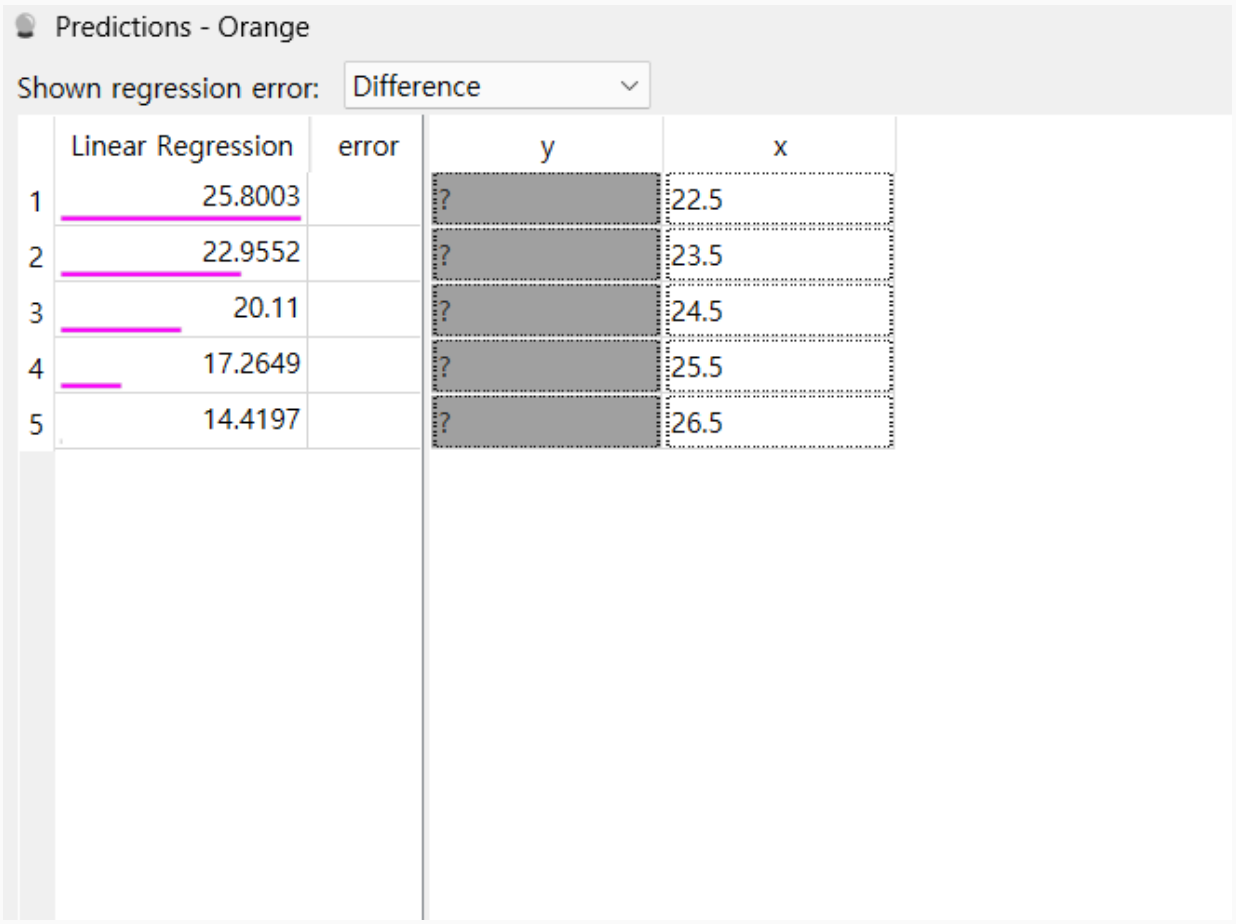


데이터 점들이 어떤 방향으로 분포하나요? (예: 왼쪽 아래 → 오른쪽 위) 두 변수의 관계(양/음의 방향)와 직선 경향의 강도를 설명하세요.

점들이 왼쪽 위에서 오른쪽 아래로 분포한다. 전기차 보급률과 초미세먼지 농도는 음의 상관관계를 보이며, 상관계수는 0.87으로 아주 강한 상관관계를 의미한다.

2-3 예측 결과 비교 (내 손 계산 vs Orange3)

Predictions 위젯의 예측 결과 화면을 캡처



x 값	내가 계산한 예측값 **(y=ax+b)**	**Orange3** 예측값
22.5	27	25.8003
23.5	24.2	22.9552
24.5	21.4	20.11
25.5	18.6	17.2649
26.5	15.8	14.4197

영역 3	결과 검증 및 해석	[10점]

📋 평가요소 (배점 근거)

① 회귀선과 평가지표(R²·MAE·RMSE)로 예측 결과의 타당성을 검증하였는가? → 3-1

② 정비례·반비례 등 관계의 방향과 의미를 데이터 맥락에서 해석하였는가? → 3-2

③ 모델의 한계(외삽의 위험)를 탐구하고, 활동을 통해 배운 점을 성찰하였는가? → 3-3·3-4

3-1 회귀선으로 타당성 검증

내 손 계산값과 Orange3 예측값이 비슷한가요? 예측 점들이 산점도의 회귀선 위/근처에 놓이나요? 이 모델이 데이터의 규칙을 잘 학습했다고 판단한 근거를 쓰세요.

내가 규칙에 따라 예측한 결과와 모델의 예측 결과가 비슷했다. Orange3의 예측값이 회귀선 위에 잘 놓이므로, 모델이 데이터의 규칙을 잘 학습했다고 판단하였다.

3-1-2 모델 평가지표로 신뢰도 검증 (Test and Score · 심화)

🌟 **(심화) Test and Score**로 모델의 신뢰도를 '숫자'로 검증하기

① **[Evaluate] → [Test and Score]** 위젯을 추가한다.

② **train data(File)**를 **Data**로, **Linear Regression**을 **Learner**로 각각 연결한다.

③ 평가 방법은 **Cross validation**(교차검증, 기본값)으로 두고 아래 세 지표를 읽어 기록한다.

(MSE·MAPE도 함께 나오지만 **R²·MAE·RMSE**에 집중. **RMSE = MSE**의 제곱근)

평가지표	내가 기록한 값	이 값이 뜻하는 것 (내 해석)
R² (결정계수)	0.582	초미세먼지 농도 감소에는 전기차 보급률 이외에도 다른 요인들이 영향을 미친다.
MAE (평균오차)	2.272	이 모델을 가지고 예측한 값에서도 2.272 정도의 오차가 있을 수 있을 것이다.
RMSE	3.555	MAE와 비해 더 큰 걸 보아 회귀선을 벗어나는 이상치가 있었다.

위 지표로 볼 때 내 모델은 얼마나 믿을 만한가요? 아래를 근거로 설명하세요.

① R²는 1에 얼마나 가까운가? (예측이 데이터를 잘 설명하는가)

R^2(결정계수)는 0.582였다. 이 모델이 데이터의 58.2%를 설명한다는 뜻으로, 전기차 보급률이 실제 초미세먼지 농도 감소 중 약 58.2%를 설명한다고 할 수 있다. 이는 전기차 보급률과 초미세먼지 농도 사이에 상관관계가 존재하지만, 초미세먼지 농도를 결정하는 데에는 전기차 보급률 이외에도 계절, 공장

매연 등 다른 요인이 영향을 미친다는 것을 보여준다.

② RMSE가 MAE보다 크다면, 그 이유는 무엇일까? (크게 빗나간 이상치)

다는교차 검증 결과, RMSE가 3.555로 2.272인 MAE보다 높게 나왔다. 이는 데이터 중 회귀선을 크게 벗어나는 이상치가 있다는 것을 알려준다. 훈련 데이터의 3월 달 자료는 전기 차 보급률에 비해 초미세먼지 농도가 높아 회귀선의 위쪽에 붕 떠 있었다. 이는 계절의 요인으로 이상치가 나왔다고 해석할 수 있었다.

③ [심화] Test and Score 점수는 '처음 보는 데이터로 시험 본' 교차검증 점수입니다. 전체 데이터에 그냥 맞췄을 때(훈련)보다 왜 조금 낮을까요?

학습에 데이터만을 가지고 회귀 분석을 했을 때에 비해 실제 데이터를 가지고 예측한 값이 정확도가 떨어지기 때문이다. R^2(결정계수)는 회귀 모델의 일반화 성능을 나타내는데, 회귀선의 상관계수였던 0.87을 제곱한 0.7569에 비해 결정계수는 0.582로 더 작았다. 이는 회귀 분석 모델이 새로운 데이터를 예측할 때 정확도가 떨어진다는 것을 의미한다.

3-2 결과 해석 — 숫자 뒤의 의미

x와 y는 정비례·반비례 중 어느 관계인가요? 기울기의 크기가 뜻하는 바는? 이 예측 결과를 실생활에서 어떻게 활용할 수 있을지 내 주제의 맥락으로 해석하세요.

X와 y는 반비례하는 관계이다. 기울기는 -2.84515이고, 상관계수는 0.87로 매우 강한 음의 상관관계를 보여준다. 초미세먼지 농도의 감소에는 전기차 이외의 계절, 강수량, 공장 가동 시간 등의 요인이 있겠지만,

3-3-1 한계 탐구 — 극단값 실험 (외삽의 위험)

🤔 학습 데이터 범위를 크게 벗어난 x값을 회귀식에 넣으면 예측이 현실적으로 말이 될까요?
외삽(Extrapolation)의 위험을 확인해 봅시다.

극단적인 **x** 값	모델 예측값 **y**	현실적으로 가능한가**?**
0(전기차 없음)	89.8162	초미세먼지 '매우 높음' 수준으로 신체에 치명적인 정도이다, 전기차가 없었을 당시에도 이런 수준의 초미세먼지 농도는 없었으므로 현실적으로 불가능하다.
1000 (모든 자동차가 전기차)	-2755.33	모든 사람이 전기차를 쓸 때의 예측값이 음수가 나왔다! 초미세먼지가 없다 못해 마이너스가 되는 기적의 상황이라고 보긴 어렵고, 데이터 범위 밖에 있는 값을 넣은 외삽으로 볼 수 있다.

극단값에서 예측이 현실과 맞지 않는(또는 맞는) 이유를 설명하세요. 선형 회귀는 어떤 범위에서 신뢰할 수 있을까요?

학습시킨 데이터 범위 바깥에 있는 값을 넣게 되면 회귀선을 범위 바깥까지 연장시키므로, 예측값의 신뢰성이 떨어진다. 훈련 데이터의 범위 내를 넣어야 믿을 수 있는 예측이라고 할 수 있다.

3-3-2 활동 성찰

📝 활동을 돌아보며 이번 활동에서 '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지'와, 선형 회귀로 예측할 때 주의할 점(3-3의 외삽 실험과 연결)을 함께 정리하세요. 성실히 쓰면 세특(세부능력 및 특기사항) 작성의 좋은 소재가 됩니다.

📝 활동 성찰 — '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지' 흐름으로 쓰면 세특 작성의 좋은 소재가 됩니다.

처음에는 독립변수 x를 전기차 수로 했는데, 초미세먼지 농도에 비해 값이 너무 커 회귀선의 기울기가 너무 복잡하게 나왔다. 독립변수를 전기차 수를 전체 차량 수로 나눈 전기차 보급률로 바꿔서 문제를 해결했다. X와 y값을 알맞게 정해야 효용 있는 그래프가 나올 수 있음을 깨달았다.

📚 핵심 개념 요약

· 지도학습 : 정답(레이블)이 있는 데이터로 모델을 훈련시키는 방법

· 회귀(Regression) : 연속적인 숫자 값을 예측하는 문제 유형

· 선형 회귀 : y = ax + b 직선으로 데이터의 패턴을 표현하는 알고리즘

· 기울기 a의 부호 : a>0이면 양의 관계(정비례), a<0이면 음의 관계(반비례)

· 외삽(Extrapolation)의 위험 : 학습 데이터 범위를 벗어난 예측은 신뢰하기 어려움

· 결정계수(R^2) : 모델이 데이터를 설명하는 비율(0~1). 단순 선형회귀에서는 상관계수의 제곱($R^2=r^2$)

· MAE / RMSE : 예측 오차의 크기(작을수록 좋음). RMSE는 큰 오차(이상치)에 더 민감

· 교차검증(Cross validation) : 데이터를 나눠, 학습에 쓰지 않은 부분으로 평가 → 모델의 '진짜 실력(일반화 성능)' 측정

· 훈련 vs 검증 성능 : 본 데이터엔 잘 맞고(훈련), 처음 보는 데이터엔 조금 못 맞음(검증). Test and Score 값이 검증 성능

🔎 수행평가 채점표 (교사 기입용)

채점 기준: 아래 참고

※ 저작권·데이터 윤리 미준수, 평가 윤리 미준수, AI 활용 금지 원칙 위반 등 부적절 상황 발생 시 해당 영역 0점 처리.

평가영역	배점	채점 기준 (해당 점수에 ○)	획득 점수
[영역1] 데이터 이해 및 회귀식 추정	10점	10 · 8 · 6 · 4	
[영역2] Orange3 예측 모델 구성	10점	10 · 8 · 6 · 4	
[영역3] 결과 검증 및 해석	10점	10 · 7 · 4 · 1	
합계	**30**점	기본점수 9점	**/ 30**